分块策略

分块为什么重要

检索的基本单位是分块，不是整篇文档。分块太粗，一个向量里混入多个主题，检索时语义被稀释；分块太细，片段缺少上下文，模型难以理解。

分块是检索质量的上限。检索没召回，后面的重排和生成都无法补救。

固定窗口

最直接的做法是按固定字符数切分，例如每 ８００ 字一块，相邻块重叠 １２０ 字。

优点是实现简单、行为可预测、每块长度稳定。缺点是可能从句子中间或章节中间切断，引用时读起来突兀。

重叠可以缓解切断问题，但会带来重复内容，增加索引体积和检索时的冗余。

标题感知

对 Ｍａｒｋｄｏｗｎ 笔记，可以按标题切分：每个标题开启一个新节，节内再按长度切。

这样每个分块天然带有主题，引用时可以显示 " 某文件 > 某小节 " 。标题还可以拼进嵌入文本，帮助模型区分相似但主题不同的片段。

代价是分块长度不均匀。短小节可能只有一两句话，长小节仍然需要二次切分。实现上要处理标题层级和空节。

语义分块

更复杂的方法是用句子嵌入判断相邻句子的相似度，在主题变化处断开。它可能得到更自然的分块，但需要额外计算，参数也难调。

对个人知识库，标题感知加长度上限通常已经够用，语义分块属于可选的优化项。

参数怎么定

块大小要匹配嵌入模型的能力和引用展示的需要。中文技术笔记常用的范围是 400 到 800 字。

重叠只在强制切分时使用，避免每个块都携带重复内容。具体数值应通过评测集比较 Recall@5 和引用准确率后确定，而不是照搬别人的配置。