中文嵌入模型

嵌入模型做什么

嵌入模型把一段文本映射成一个固定维度的向量。语义相近的文本，向量方向也相近。检索时比较问题向量和文档向量的余弦相似度，就能找到语义相关的片段。

嵌入模型的维度不是越高越好。维度高表达能力更强，但存储和计算成本也更高。对个人知识库，１０２４　维已经足够。

ｂｇｅ-ｍ３

ｂｇｅ-ｍ３　是　ＢＡＡＩ　发布的多语言嵌入模型，支持中文、英文等多种语言。它输出　１０２向量，最长可以处理　８１９２　个　ｔｏｋｅｎ。

ｂｇｅ-ｍ３　还支持稀疏权重和多向量表示，但通过　Ｏｌｌａｍａ　调用时通常只使用稠密向量。部分可以用独立的分词加　ＢＭ２５　方案补齐。

在本地运行时，ｂｇｅ-ｍ３　的显存占用约　０．７ＧＢ，单条文本的嵌入延迟在十几毫秒量级，适实时检索。

余弦相似度的直觉

余弦相似度关注两个向量的夹角，不关注长度。取值范围是负一到一，越接近一越相似。

实际使用中，不同模型的分数量纲差异很大。ｂｇｅ-ｍ３　对完全不相关的两段中文也可能给出０．３　以上的分数，所以阈值必须针对具体模型和语料校准。

一个常见误区是拿一个通用阈值套所有模型。正确做法是构造＂相关问题　+　无关问题＂的小评测集，观察分数分布，再选一个能分开两者的值。

归一化与距离

如果向量已经归一化，余弦相似度和点积等价。Ｑｄｒａｎｔ　的　Ｃｏｓｉｎｅ　距离内部会做归一此存入的向量长度不影响排序。

选择距离函数时要和嵌入模型的训练目标一致。大多数句向量模型使用余弦相似度，直接用 Ｃｏｓｉｎｅ 即可。

中文的特殊问题

中文没有空格，分词质量会影响稀疏检索。稠密检索对分词不敏感，但也会受训练数据影响。

对于中英混合的技术笔记，建议选择多语言模型，并在分块时保留标题，让片段自带上下文。标题参与嵌入通常能明显提升召回。