混合检索

稠密检索与稀疏检索

稠密检索把文本映射为固定维度的向量，用余弦相似度衡量语义接近程度。它擅长处理同义改写和概念关联，例如 " 怎么让搜索更准 " 可以匹配到 " 提升召回率的方法 " 。

稀疏检索基于词项匹配，典型代表是 ＢＭ２５。它给每个词计算逆文档频率，再结合词频和文档长度归一化打分。稀疏检索擅长精确匹配专有名词、编号、错误码和罕见术语。

两类方法各有盲区：稠密检索可能漏掉精确字符串，稀疏检索无法理解同义表达。把两路结果融合，通常比任何单路都稳定。

ＢＭ２５ 的直觉

ＢＭ２５ 的分数由三部分组成：词越罕见，权重越高；词在文档里出现次数越多，分数越高，但增长会饱和；文档越长，同样词频的权重越低。

因此 ＢＭ２５ 不需要训练，计算便宜，可解释性强。它的弱点是依赖分词质量。中文没有天然空格，如果分词器把整句当成一个词，ＢＭ２５ 就完全失效。

ＲＲＦ 融合

ＲＲＦ（Ｒｅｃｉｐｒｏｃａｌ Ｒａｎｋ Ｆｕｓｉｏｎ）只使用排名，不使用原始分数：

ｓｃｏｒｅ（ｄ） ＝ Σ １ ／ （ｋ ＋ ｒａｎｋ＿ｉ（ｄ））

其中 ｋ 通常取 ６０，ｒａｎｋ＿ｉ（ｄ） 是文档在第 ｉ 路结果中的名次。两路都靠前的文总分。

ＲＲＦ 的好处是不用把余弦相似度和 ＢＭ２５ 分数校准到同一量纲，实现简单，对异常分数不敏感。代价是丢失了分数差距信息，例如第一名远超第二名这一点在 ＲＲＦ 里看不出来。

工程取舍

混合检索需要维护两套索引，写入和查询成本都增加。对 1k 到 5k 文件的个人知识库，这个成本可以接受，因为检索质量直接决定引用准确率。

常见参数是每路各取 20 个候选，融合后交给重排模型。候选太少会漏召回，太多会增加重排延迟。具体数值应通过评测集确定，而不是凭感觉设置。