Ｑｄｒａｎｔ　使用笔记

集合与向量

Ｑｄｒａｎｔ　用集合（ｃｏｌｌｅｃｔｉｏｎ）组织向量。创建集合时要指定向量维度、距离函数和名向量。

命名向量允许同一个点携带多路向量，例如一个稠密向量和一个稀疏向量。混合检索正是利用这一点：两路向量存在同一个点里，查询时分别召回，再融合结果。

Ｐａｙｌｏａｄ　与过滤

每个点可以携带　ｐａｙｌｏａｄ，用来存原文、文件路径、标题、行号等元数据。检索时可以按　ｐｙｌｏａｄ　过滤，例如只搜某个资料源，或者排除某些目录。

ｐａｙｌｏａｄ　不适合存大量结构化业务数据。文档、分块、会话这类需要事务和关联查询的信息，放在关系型数据库里更合适，向量库只负责相似度检索。

稀疏向量与　ＩＤＦ

Ｑｄｒａｎｔ　支持稀疏向量，适合　ＢＭ２５　这类词项加权模型。稀疏向量只存非零维度和对应权，空间效率高。

如果使用服务端的　ＩＤＦ　修饰符，集合会在统计意义上自动计算逆文档频率。写入时只需要提供词频，查询时也提供词频，Ｑｄｒａｎｔ　会把　ＩＤＦ　应用到打分中。

这要求集合配置正确。如果忘记开启　ＩＤＦ　修饰符，打分退化成简单的词频点积，罕见词的优势就消失了。

查询接口

早期版本使用　ｓｅａｒｃｈ　接口，新版本推荐　ｑｕｅｒｙ＿ｐｏｉｎｔｓ。它支持预取（ｐｒｅ询：可以先分别取稠密和稀疏的候选，再用　ＲＲＦ　融合。

预取的　ｌｉｍｉｔ　决定每路候选数量。融合后的　ｌｉｍｉｔ　决定最终返回数量。两者要分开设

容易误以为融合没有生效。

运维注意

向量库通常以容器方式运行，只监听本机端口。数据目录要挂载到宿主机，否则容器删除后索引丢失。

索引可以重建，所以向量数据不是必须备份的内容；但原始文档和元数据数据库必须备份。重建索引的时间取决于文件数量和嵌入速度。