重排模型

为什么需要重排

向量检索是双塔结构：问题和文档分别编码，最后只比较两个向量。它快，但问题和文档在编码阶段没有互相看见，细粒度的相关性判断较弱。

重排模型通常是交叉编码器（Ｃｒｏｓｓ－Ｅｎｃｏｄｅｒ）。它把问题和候选文档拼在一起送入模型，输出一个相关性分数。因为注意力可以同时看到问题和文档，判断更准确，但每个候选都要单独推理，成本高。

所以常见架构是＂召回　＋　重排＂：先用便宜的向量检索取回　２０　到　５０　个候选，再用重排排，取前　５　个交给生成模型。

ｂｇｅ－ｒｅｒａｎｋｅｒ－ｖ２－ｍ３　的特点

ｂｇｅ－ｒｅｒａｎｋｅｒ－ｖ２－ｍ３　是多语言交叉编码器，支持中英文，输入是＂问题　＋　文相关性分数。经过　ｓｉｇｍｏｉｄ　后可以理解为　０　到　１　的相关概率。

实测中，明确相关的样本得分接近　１，明确无关的样本接近　０。部分相关的样本可能落在　０．１　到　０．２　之间，所以拒答阈值不能只看一个固定数字，要在评测集上校准。

延迟与显存

重排的成本与候选数量成正比。在　８ＧＢ　显存的笔记本上，２０　个短片段的重排大约需要一百多毫秒，模型加载需要数秒。

如果重排模型与生成模型、嵌入模型同时驻留，显存会很紧张。可行的降级顺序是：把重排放到　ＣＰＵ、改成按需加载、或者减少候选数量。无论哪种，都要先测量再决定。

重排与拒答

重排分数可以作为拒答依据之一：如果最高分低于阈值，说明资料里可能没有相关内容，此时不调用生成模型，直接返回＂资料中未找到足够依据＂。

这样做有两个好处：避免模型在没有证据时编造，也节省一次云端调用。阈值需要在有答案和无答案的评测题上同时校准，避免误拒和漏拒。